Faculdade de
Computação e Informática

MANUAL DE ANOTAÇÃO DE DISCURSO DE ÓDIO POLÍTICO

Proposta de protocolo para classificação binária de publicações em redes sociais

Trabalho de Conclusão de Curso

Detecção de Discurso de Ódio Político em Redes Sociais por meio de Redes Neurais em Grafos

Carlos Eduardo Hayashi
Edson Luiz Cardoso Ohira
Vinicius Oliveira Piccazzio

Orientador: Prof. Ivan Carlos Alcântara de Oliveira

São Paulo

2026

1. Finalidade e escopo

Orientar avaliadores humanos a identificar, de forma consistente e justificável, discurso de ódio político em mensagens curtas em português publicadas em redes sociais. A unidade de anotação é uma publicação textual; quando disponível e permitido, o contexto imediato pode auxiliar na interpretação, sem substituir o conteúdo efetivamente avaliado.

A tarefa é BINÁRIA: ÓDIO POLÍTICO (1) ou NÃO ÓDIO POLÍTICO (0). Não se classifica o posicionamento político do autor, a veracidade de uma notícia, a toxicidade genérica ou a concordância do avaliador com a mensagem.

2. Definição operacional

ÓDIO POLÍTICO (1): mensagem que contém agressão dirigida a pessoa ou grupo em razão de sua posição, identidade, filiação ou atuação política, incluindo ofensas pessoais degradantes, desumanização, desejo de dano, ameaça ou incitação à violência/discriminação motivada politicamente.

NÃO ÓDIO POLÍTICO (0): crítica a decisões, ideias, governos, partidos ou figuras públicas, mesmo severa ou emocional, sem agressão dirigida a pessoas/grupos nos termos acima; relato, condenação, citação não endossada ou debate político sem ataque pessoal motivado politicamente.

Importante: discordância, oposição, linguagem enfática e uso de palavras negativas não bastam para classificar uma publicação como ódio político. Da mesma forma, não é necessário que exista uma palavra de uma lista proibida para haver ódio.

3. Princípios de anotação

- Neutralidade política: aplicar os mesmos critérios independentemente do partido, candidato, movimento ou ideologia citados.
- Foco no alvo e na conduta: identificar quem é atacado e se a agressão decorre de sua posição/atuação política.
- Contexto sem extrapolação: não presumir intenção oculta quando a mensagem não fornece elementos suficientes.
- Citação e condenação: distinguir reproduzir uma agressão para criticá-la de endossá-la.
- Justificativa rastreável: registrar uma evidência textual curta para cada decisão.
- Confidencialidade: não divulgar mensagens reais, identificadores, nomes de usuário ou dados da coleção fora do ambiente autorizado.

4. Fluxo de decisão

Etapa	Pergunta	Orientação
1	Há referência política explícita ou contextual suficientemente clara?	Se não, classificar 0 nesta tarefa; registrar observação se houver toxicidade não política.
2	Existe pessoa ou grupo como alvo de agressão?	Se a mensagem apenas critica ideias, medidas ou instituições, tender a 0.
3	Há insulto dirigido, desumanização, ameaça, desejo de dano ou incitação?	Se sim, avaliar a relação com posição ou atuação política.
4	A agressão é motivada por identidade/posição/atuação política?	Se sim e a mensagem endossa o ataque, classificar 1.
5	É citação, denúncia, ironia ou mensagem ambígua?	Examinar marcas de endosso/repúdio; registrar dúvida e encaminhar para revisão se necessário.

5. Casos limítrofes e regras práticas

Crítica política contundente
"A gestão foi incompetente e prejudicou o país" é crítica a desempenho, não ataque pessoal motivado politicamente.

Insulto pessoal político
Chamar eleitores de determinado grupo de "vermes" ou "lixo humano" configura desumanização/agressão ao grupo.

Ameaça e incitação
Defender agressão física a apoiadores ou opositores políticos recebe rótulo 1, mesmo que a frase não use palavrões.

Ironia e sarcasmo
Não rotular automaticamente por marcadores como "kkk" ou emojis; identificar o alvo e o sentido provável.

Citação/denúncia
"Disseram 'expulsem todos os eleitores de X'; isso é absurdo" tende a 0, pois há repúdio explícito.

Referência a figura pública
Críticas duras a atos de um político não são automaticamente ódio; ataques degradantes à pessoa por sua atuação política podem ser 1.

Ofensa sem contexto político
Uma agressão interpessoal sem vínculo político claro não recebe 1 nesta tarefa, embora possa ser ofensiva.

Conteúdo incompleto
Quando a mensagem truncada não permite identificar alvo, motivação ou endosso, marcar 0 provisoriamente e sinalizar "contexto insuficiente" para revisão.

6. Exemplos de anotação (mensagens sintéticas)

ID	Mensagem sintética	Rótulo	Justificativa
E01	"Discordo totalmente do projeto desse partido. É uma proposta ruim."	0	Crítica à proposta, sem ataque a pessoas.
E02	"Os eleitores do partido Azul são vermes e deveriam desaparecer."	1	Desumanização de grupo definido por preferência política.
E03	"O governo falhou e precisa ser cobrado nas urnas."	0	Cobrança política legítima.
E04	"Quem apoia esse candidato merece apanhar na rua."	1	Endosso de violência contra apoiadores políticos.
E05	"É revoltante ver tanta corrupção; quero investigação e punição legal."	0	Defesa de responsabilização legal, sem violência.
E06	"Chamaram os manifestantes de 'animais'; esse tipo de fala é inaceitável."	0	Reprodução para condenar a ofensa.
E07	"Esse deputado é um parasita imundo; gente assim não deveria existir."	1	Ataque degradante e desejo de eliminação contra figura por atuação política.
E08	"Que discurso ridículo! Não concordo com nenhuma palavra."	0	Rejeição ao discurso, sem agressão dirigida.
E09	"Precisamos expulsar à força todos os apoiadores do movimento Verde."	1	Incitação à coerção contra grupo político.
E10	"Nossa, que 'gênio' esse ministro... mais uma decisão desastrosa 🙄"	0	Sarcasmo sobre decisão, sem agressão pessoal degradante.
E11	"Fulano é um idiota."	0*	Sem contexto político explícito; sinalizar contexto insuficiente se necessário.
E12	"Não deixem os simpatizantes de X entrarem no bairro; eles não são gente."	1	Discriminação e desumanização de grupo político.

* E11 ilustra a regra operacional conservadora proposta para casos sem vínculo político demonstrável. Uma política de anotação diferente poderia tratar ofensas pessoais de outra maneira; os autores devem fixar a regra antes de aplicar o manual.

7. Formulário de registro por anotador

Campo	Conteúdo esperado
id_texto	Identificador pseudonimizado da publicação
id_anotador	Código do avaliador, sem nome na planilha compartilhada
rotulo	0 = não ódio político; 1 = ódio político
alvo	Pessoa; grupo político; instituição/ideia; não identificado
evidencia	Expressão ou construção que sustenta o rótulo
tipo_indicio	Crítica; insulto; desumanização; ameaça; incitação; citação/repúdio; outro
confianca	Alta; média; baixa (campo auxiliar, não uma terceira classe)
revisao	Sim/não e motivo: ironia, contexto insuficiente, citação, alvo incerto

8. Procedimento de anotação e consolidação

1. Preparação: fornecer aos três avaliadores o mesmo conjunto de instruções e exemplos, sem identificação partidária privilegiada. Recomenda-se um pequeno lote piloto, com discussão das divergências antes do lote principal.

2. Anotação independente: cada um dos três avaliadores atribui 0 ou 1 sem consultar os rótulos dos colegas. Evidências e dúvidas são registradas separadamente.

3. Consolidação: para cada publicação, o rótulo final é o da maioria simples (pelo menos dois de três avaliadores concordam). Preservar os três rótulos originais para auditoria.

4. Qualidade: calcular concordância bruta, Kappa de Fleiss e, se desejado, AC1 de Gwet; interpretar as medidas conjuntamente e discutir padrões de divergência. A concordância não substitui a verificação da qualidade das instruções.

5. Revisão: inspecionar amostras de desacordo e casos de baixa confiança, registrando eventuais ajustes futuros ao manual. Não alterar silenciosamente rótulos já consolidados.

9. Exemplo de consolidação de três avaliadores

Texto	Avaliador A	Avaliador B	Avaliador C	Maioria	Observação
E02	1	1	1	1	Concordância total
E06	0	0	1	0	Divergência sobre citação

E07	1	0	1	1	Divergência sobre ataque pessoal
E11	0	0	0	0	Contexto político insuficiente

10. Tratamento de dados, segurança e ética

- Restringir o acesso ao corpus e às planilhas aos participantes autorizados.
- Usar identificadores pseudonimizados; não compartilhar handles, URLs ou dados pessoais em relatórios públicos.
- Não republicar mensagens reais, especialmente conteúdo ofensivo, sem autorização e análise de riscos.
- Evitar exposição prolongada de avaliadores a conteúdo agressivo; prever pausas e canal para dúvidas.
- Documentar origem, período, critérios de seleção e exclusões, respeitando as condições de uso e as regras institucionais aplicáveis.

11. Checklist de qualidade antes da anotação

- O avaliador leu as definições de 0 e 1?
- Consegue distinguir crítica a políticas de agressão a pessoas/grupos?
- Sabe como tratar citação, ironia e contexto insuficiente?
- Está usando os mesmos critérios para todos os posicionamentos políticos?
- Registrará justificativa e dúvidas, além do rótulo?

12. Referência ao trabalho de origem

HAYASHI, Carlos Eduardo; OHIRA, Edson Luiz Cardoso; PICCAZZIO, Vinicius Oliveira. Detecção de Discurso de Ódio Político em Redes Sociais por meio de Redes Neurais em Grafos. Trabalho de Conclusão de Curso, Bacharelado em Ciência da Computação, Faculdade de Computação e Informática, Universidade Presbiteriana Mackenzie, 2026.